DATA VISUALIZATION

PRESENTATION

Presented by :
Rayhan Alnurron Falaqi

Data Visualization

Data visualization adalah proses menyajikan data atau informasi dalam bentuk visual seperti grafik, diagram, peta, atau dashboard agar lebih mudah dipahami dan dianalisis.

Dataset

https://www.kaggle.com/datasets/ravindrasinghrana/employeedataset

Deskripsi : Dataset ini menggunakan data karyawan yang isinya identitas,tanggal masuk/keluar,jabatan,unit bisnis,status,tipe karyawan,terminasi,demografi, dan penilaian kinerja

Program

https://github.com/rayhannnaaf/Data-Visualization.git

Deskripsi : Program ini berisi cleansing,enrichment dan visualization menggunakan beberapa teknik visualisasi seperti Histogram, Bar Chart, Boxplot, Scatter Plot, Line Chart, Heatmap.

Cleansing

Nama kolom diseragamkan ke snake_case, spasi berlebih dirapikan, placeholder kosong diubah menjadi NaN, lalu baris yang kosong total dibuang.

```
 = []
= df_raw.copy()

.1 Nama kolom -> snake_case (EmpID -> emp_id, ADEmail -> ad_email, Performance Score -> performance_score)
 snake(s):
 s = str(s).replace('\ufeff', '').strip()
 s = re.sub(r'(?<=[a-z0-9])(?=[A-Z])', '_', s)
 s = re.sub(r'(?<=[A-Z])(?=[A-Z][a-z])', '_', s)
 s = re.sub(r'[^\w]+', '_', s).strip('_')
 return s.lower()

columns = [snake(c) for c in df.columns]
.append('Nama kolom diseragamkan ke snake_case')

.2 Rapikan spasi (mis. "Production       " -> "Production") & ubah placeholder kosong -> NaN
si_diperbaiki = 0
 c in df.columns:
 asli = df[c].astype('string')
 bersih = asli.str.strip().str.replace(r'\s+', ' ', regex=True)
 spasi_diperbaiki += int(((asli != bersih) & asli.notna() & (asli.str.strip() != '')).sum())
 df[c] = bersih.mask(bersih.str.lower().isin(NILAI_KOSONG))
.append(f'Spasi berlebih dirapikan pada {spasi_diperbaiki} sel & placeholder kosong diubah menjadi NaN')

.3 Hapus baris yang kosong total
= len(df)
= df.dropna(how='all').reset_index(drop=True)
.append(f'Baris kosong total dihapus: {n0 - len(df)} (dari {n0} menjadi {len(df)} baris)')

nt('\n'.join(f'- {l}' for l in log))
nt(f'\nKolom ({df.shape[1]}):', list(df.columns))
```

Enrichment

Tanggal acuan adalah tanggal terbaru di dataset, sehingga hasilnya konsisten setiap dijalankan. Masa kerja dihitung dari start_date sampai exit_date, atau sampai tanggal acuan bila belum keluar.

```
max(), df['exit_date'].max())
']).dt.days / 365.25).round(1)
].fillna(TANGGAL_ACUAN) - df['start_date']).dt.days / 365.25).roun
.notna()
ins=[0, 30, 40, 50, 60, 120], right=False, labels=['<30', '30-39',
.date())
age_group', 'start_date', 'exit_date', 'tenure_years', 'is_termina
```

start_date	exit_date	tenure_years	is_terminated
2019-09-20	NaT	3.87	False
2023-02-11	NaT	0.48	False
2018-12-10	NaT	4.65	False
2021-06-21	NaT	2.12	False
2019-06-29	NaT	4.10	False

Histogram

histogram menunjukkan bentuk sebaran variabel numerik kontinu. Garis merah (rata-rata) dan hijau (median) dipakai untuk membaca kemiringan distribusi.

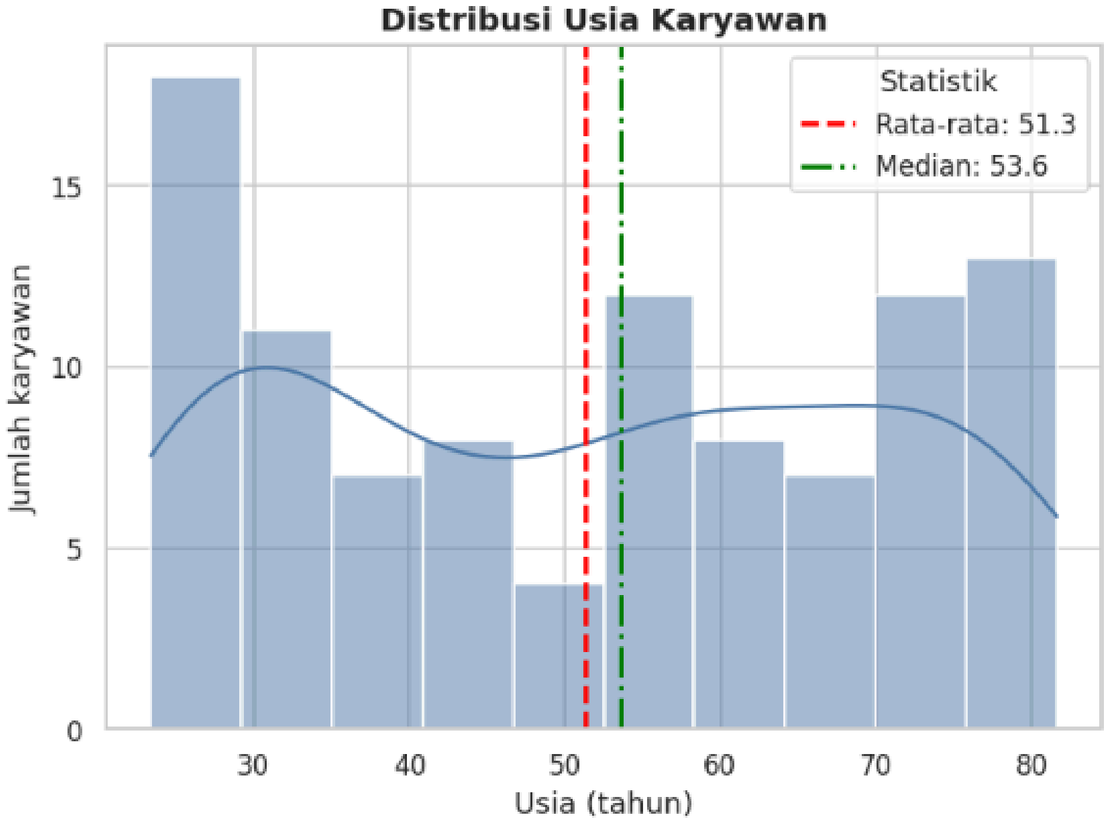
```
(13, 5))
[0], 'age', '#4C78A8', 'Distribusi Usia Karyawan'
[1], 'tenure_years', '#F58518', 'Distribusi Masa
True, color=warna, edgecolor='white', ax=ax)
ed', ls='--', lw=2, label=f'Rata-rata: {dv[col].m
'green', ls='-.', lw=2, label=f'Median: {dv[col].
el='Jumlah karyawan')

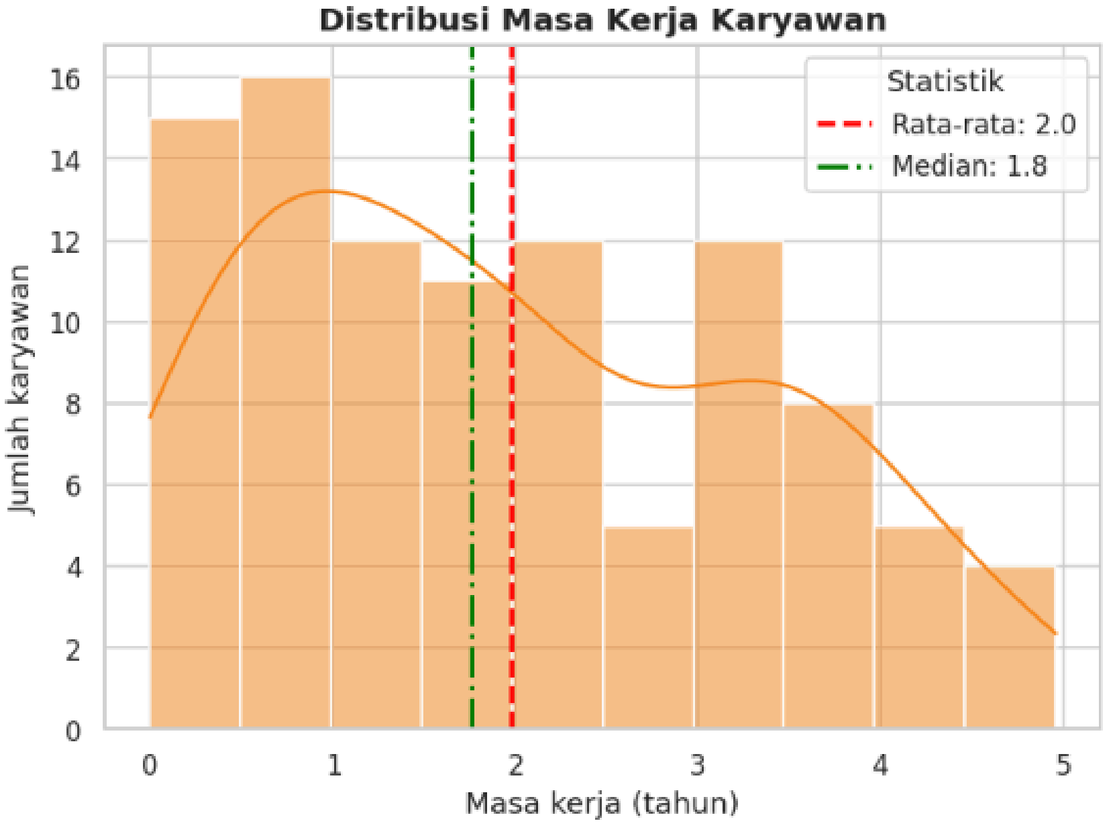
rams(integer=True)



ibe().round(2).T[['count', 'mean', '50%', 'std',
ears']].skew().round(2).to_dict())
_group'].value_counts().sort_index().to_dict())
```

output





- Insight: : tenaga kerjanya relatif baru (separuh karyawan bekerja kurang dari sekitar 1,8 tahun) dengan komposisi usia yang timpang antara sangat muda dan sangat senior. Validasi juga menandai 25 karyawan berusia di atas 70 tahun, yang tidak lazim untuk karyawan aktif dan perlu dikonfirmasi ke pemilik data.

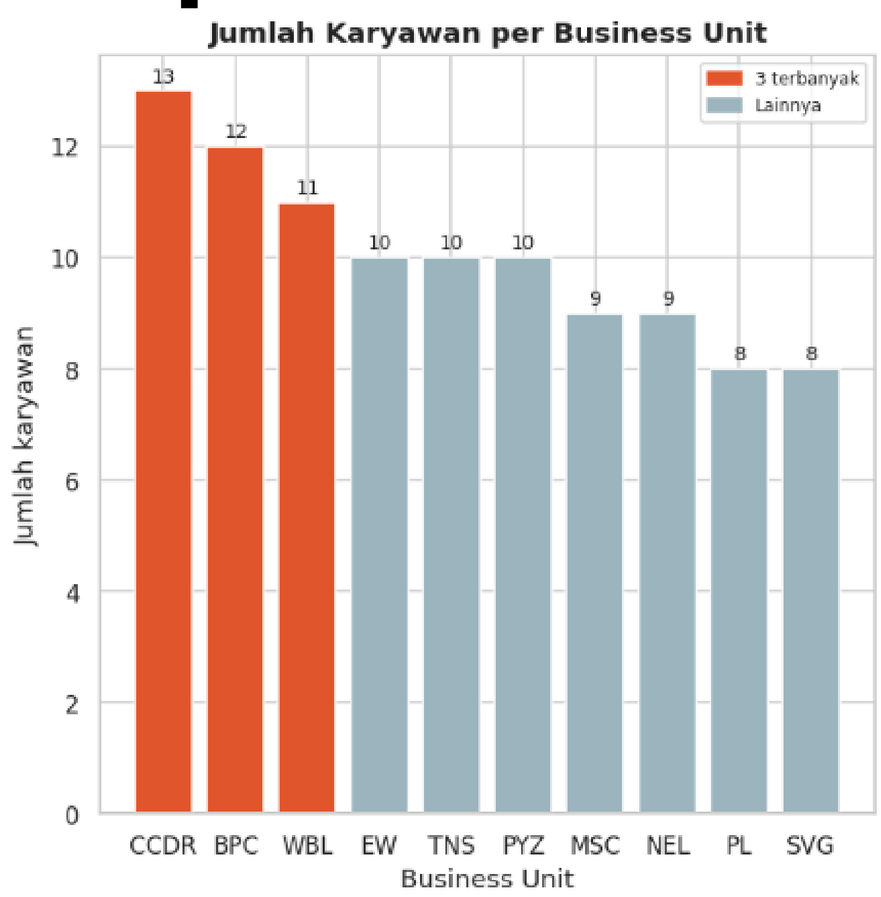
Bar Chart

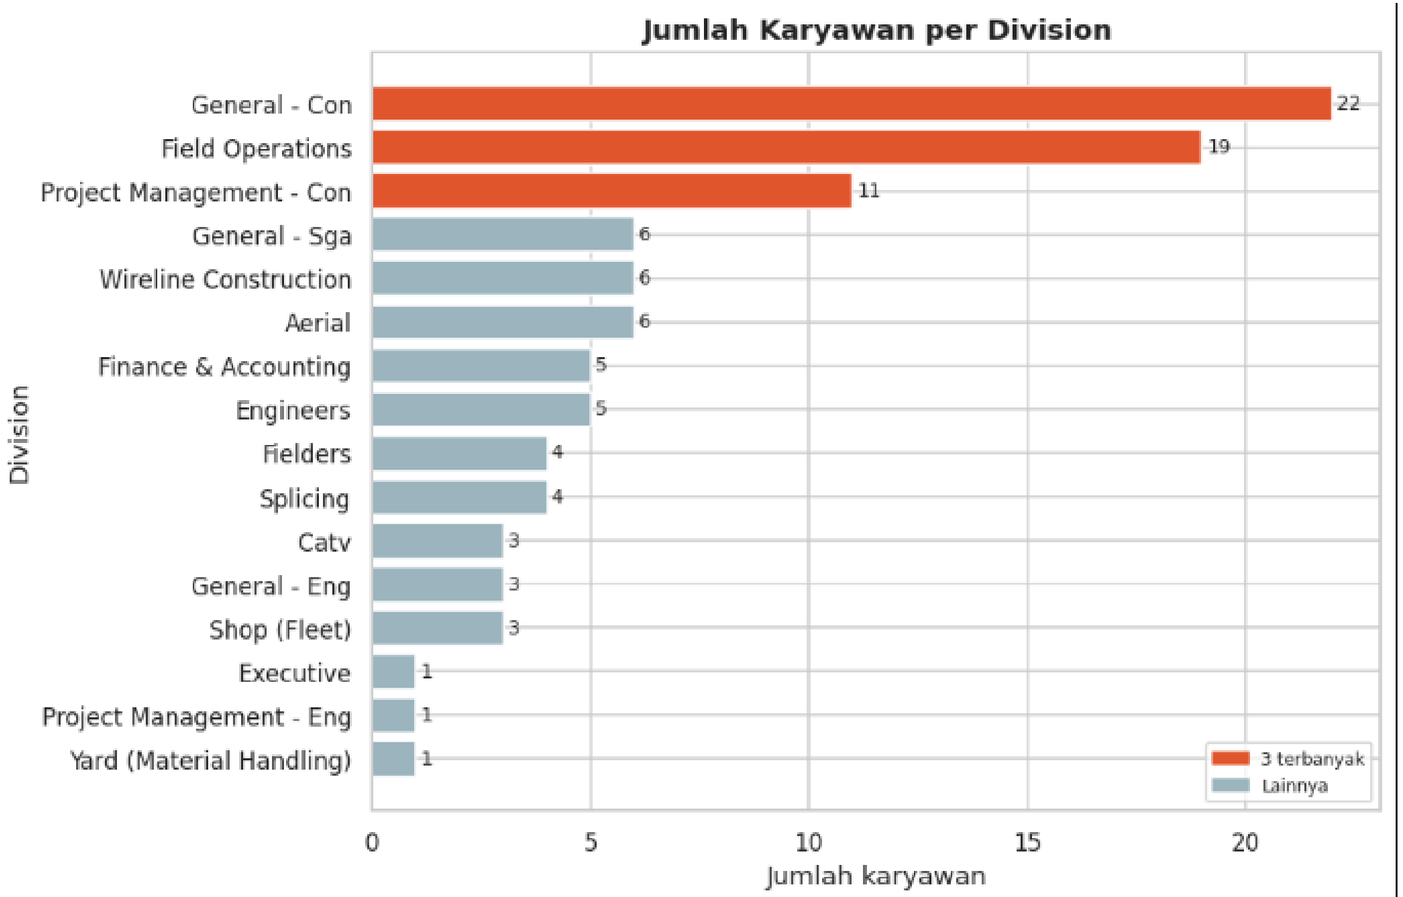
bar chart membandingkan jumlah antarkategori. Tiga kategori terbanyak diberi warna berbeda agar langsung terlihat.

```
fig, axes = plt.subplots(1, 2, figsize=(15, 6), gridspec_kw={'width_ratios': [1, 1.3]})
bu = dv['business_unit'].value_counts()
dvn = dv['division'].value_counts()
bar_hitung(axes[0], bu, 'Jumlah Karyawan per Business Unit', 'Business Unit', 'Jumlah karyawan')
bar_hitung(axes[1], dvn, 'Jumlah Karyawan per Division', 'Jumlah karyawan', 'Division', horizontal=True)
simpan('02_bar_business_unit_division')

print('Business unit :', bu.to_dict())
print('Division teratas:', dvn.head(5).to_dict(), '| jumlah division:', dvn.size)
print(f'Top-3 division = {dvn.head(3).sum() / len(dv):.0%} dari karyawan')
print('Department:', dv['department_type'].value_counts().to_dict())
```

output





- Insight: : beban dan pengelolaan SDM terpusat pada dua sampai tiga division, sementara banyak division kecil yang mungkin perlu digabung atau dilihat tersendiri dalam perencanaan SDM. Pada tingkat department, 93 dari 100 karyawan tercatat di Sales (IT/IS 5 dan Production 2), padahal nama division seperti Field Operations dan General - Con terdengar non-penjualan. Pengelompokan department perlu dikonfirmasi.

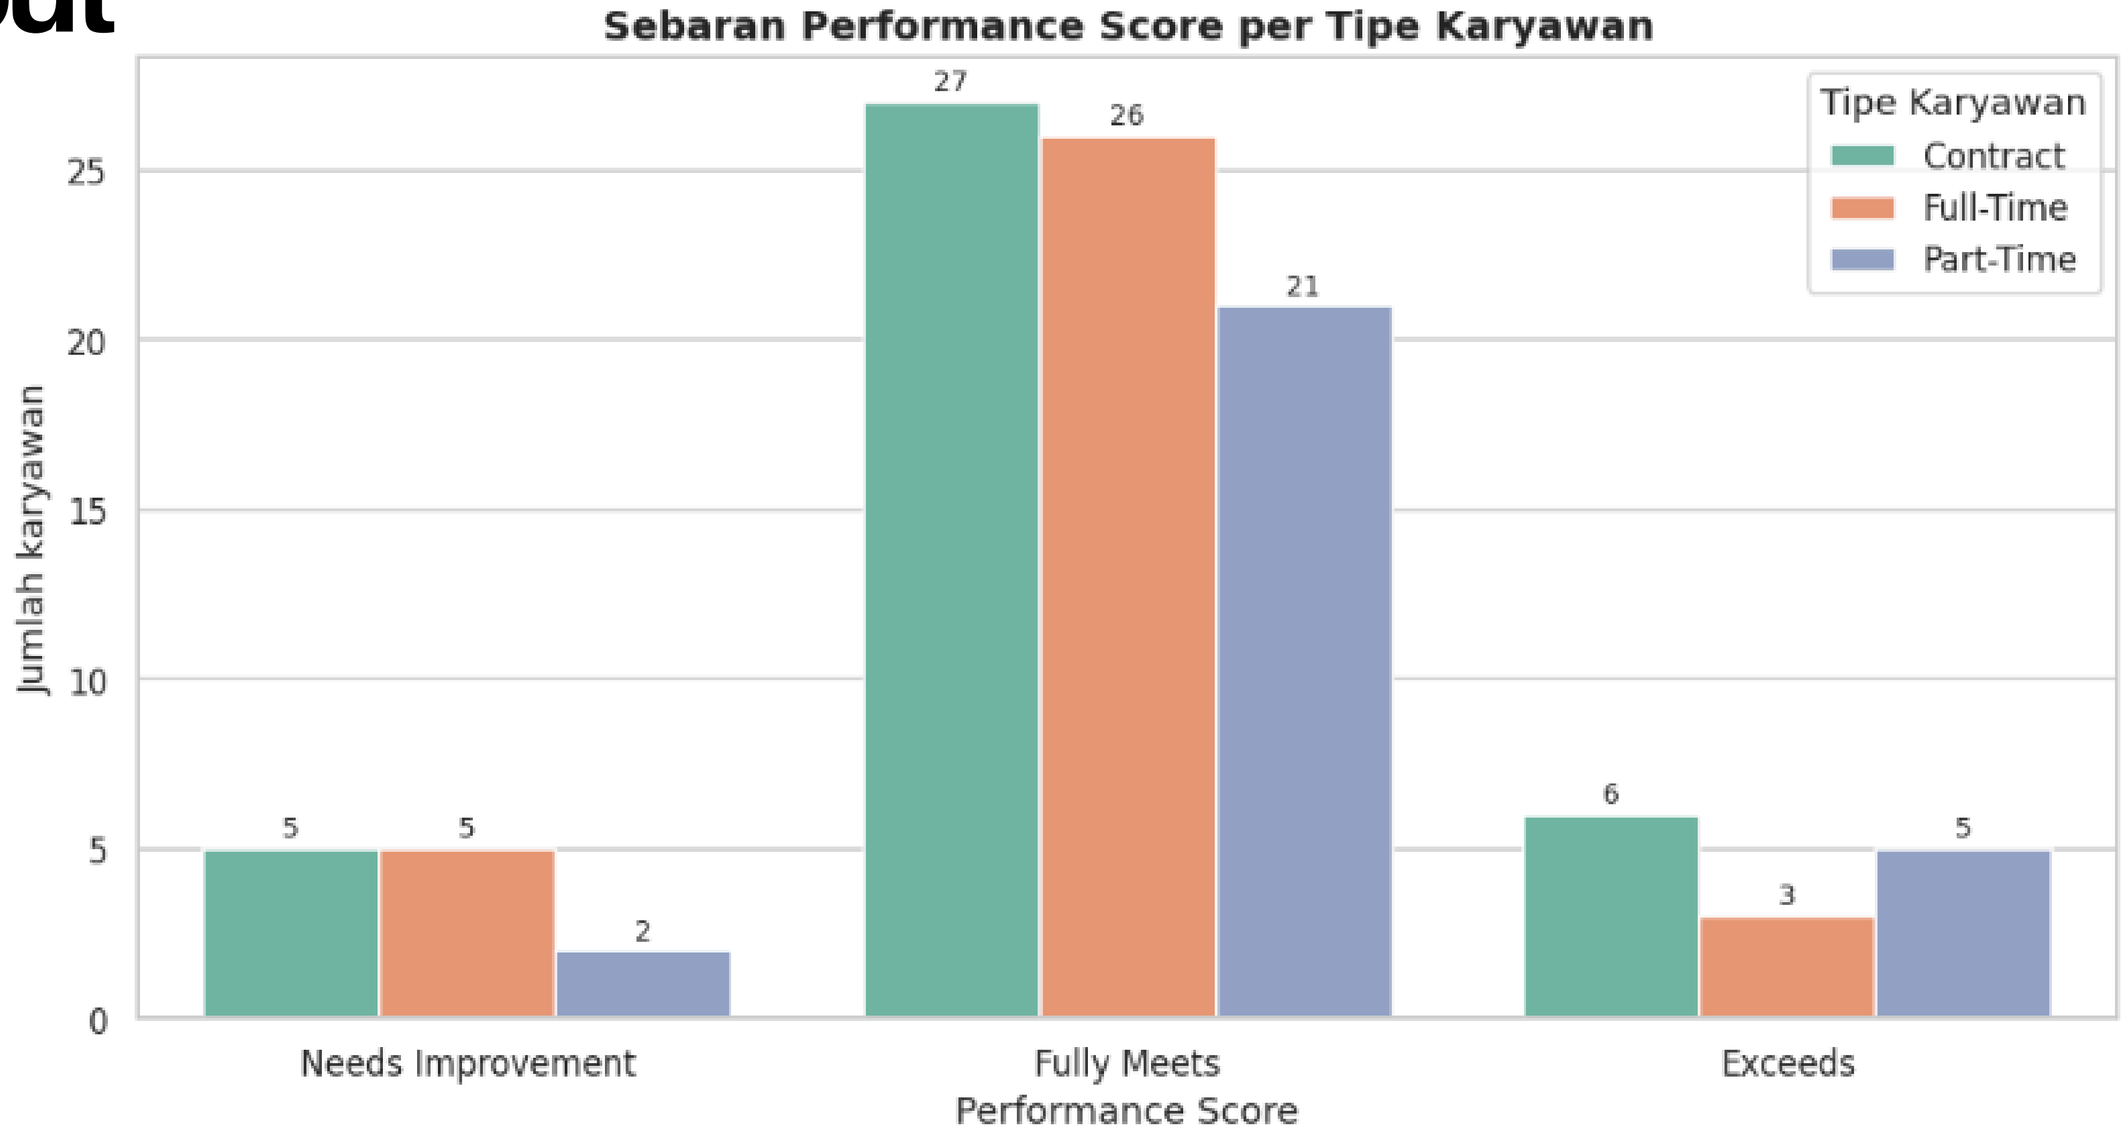
Count Plot

count plot berkelompok membandingkan sebaran kinerja antar tipe karyawan (data kategorikal vs kategorikal).

```
fig, ax = plt.subplots(figsize=(10, 5.5))
sns.countplot(data=dv, x='performance_score', hue='employee_type', order=URUT_PERF, ax=ax)
for cont in ax.containers:
    ax.bar_label(cont, fontsize=9, padding=2)
ax.set(title='Sebaran Performance Score per Tipe Karyawan', xlabel='Performance Score', ylabel='Jumlah karyawan')
ax.legend(title='Tipe Karyawan')
simpan('03_countplot_performance_tipe')

ct = pd.crosstab(dv['employee_type'], dv['performance_score'])[URUT_PERF]
print(ct)
print('\nPersentase per tipe (baris):'); print((ct.div(ct.sum(axis=1), axis=0) * 100).round(1))
print('\nTotal per performance:', dv['performance_score'].value_counts().to_dict())
```

output



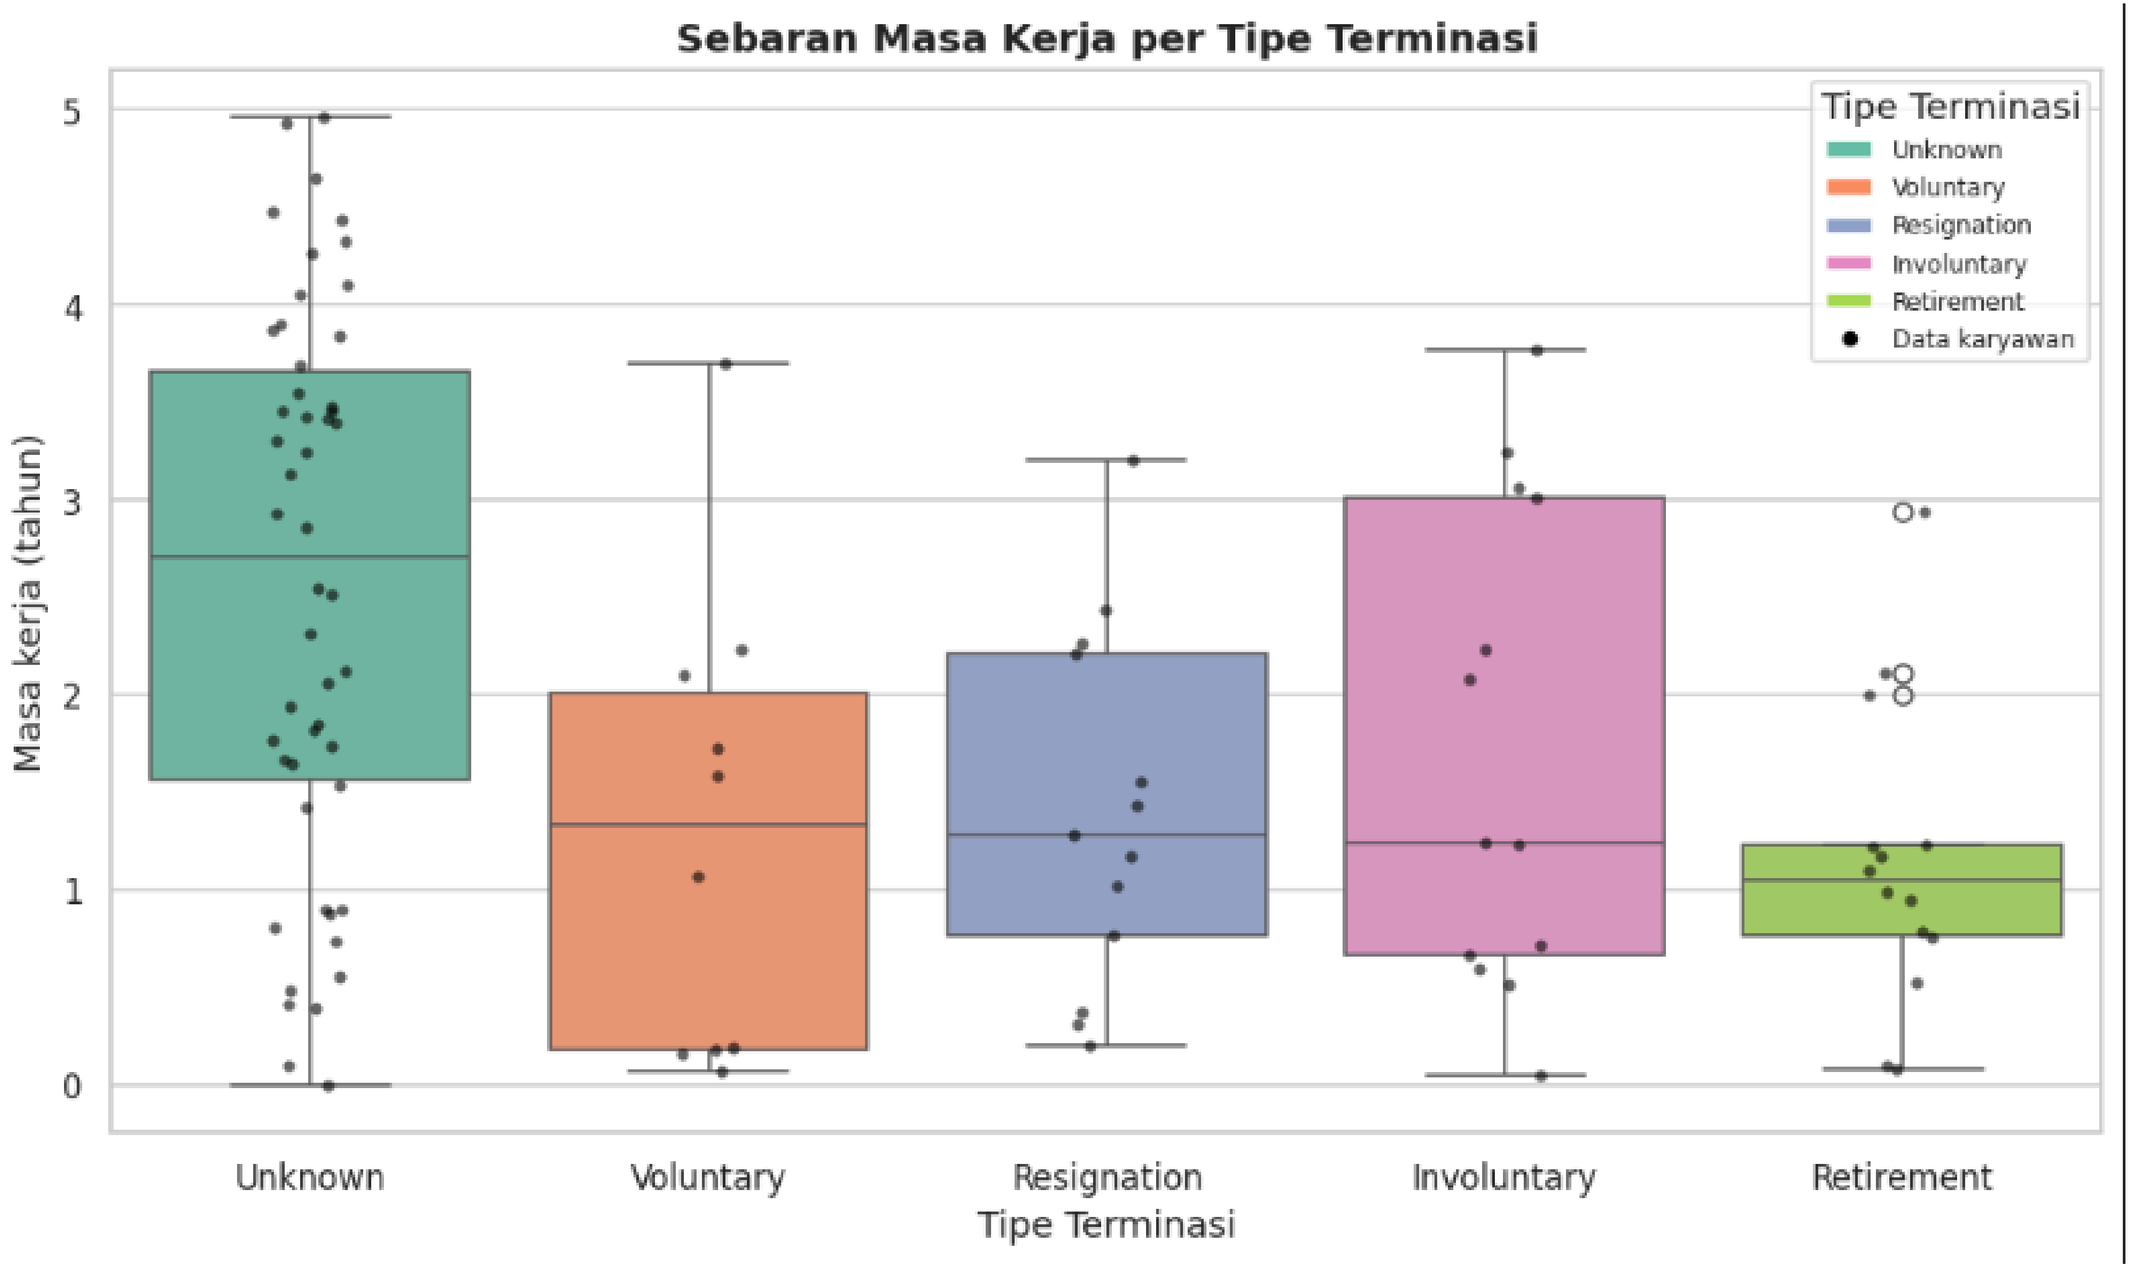
- Insight: karyawan Full-Time tampak sedikit kurang sering mendapat nilai Exceeds, tetapi selisihnya hanya 1 sampai 3 orang per kelompok dengan jumlah sampel 28–38 orang per tipe. Perbedaan ini terlalu kecil untuk disimpulkan sebagai perbedaan kinerja yang nyata; kinerja relatif seragam di semua tipe karyawan.

Boxplot

boxplot menampilkan median, kuartil, dan outlier tiap kelompok; titik hitam adalah data asli. Kategori Unknown adalah karyawan yang belum memiliki exit_date, sehingga masa kerjanya dihitung sampai tanggal acuan.

```
urut = dv.groupby('termination_type')['tenure_years'].median().sort_values(ascending=False).index.tolist()
fig, ax = plt.subplots(figsize=(10, 6))
sns.boxplot(data=dv, x='termination_type', y='tenure_years', hue='termination_type', order=urut, hue_order=urut,
            palette='Set2', legend=False, ax=ax)
sns.stripplot(data=dv, x='termination_type', y='tenure_years', order=urut, color='black', size=4, alpha=.6, ax=ax)
handles = [Patch(facecolor=WARNA[i], label=k) for i, k in enumerate(urut)]
handles.append(Line2D([0], [0], marker='o', color='w', markerfacecolor='black', markersize=6, label='Data karyawan'))
ax.legend(handles=handles, title='Tipe Terminasi', fontsize=8)
ax.set(title='Sebaran Masa Kerja per Tipe Terminasi', xlabel='Tipe Terminasi', ylabel='Masa kerja (tahun)')
simpan('04_boxplot_masa_kerja_terminasi')

print(dv.groupby('termination_type')['tenure_years'].agg(['count', 'median', 'mean', 'min', 'max']).round(2).loc[urut])
```



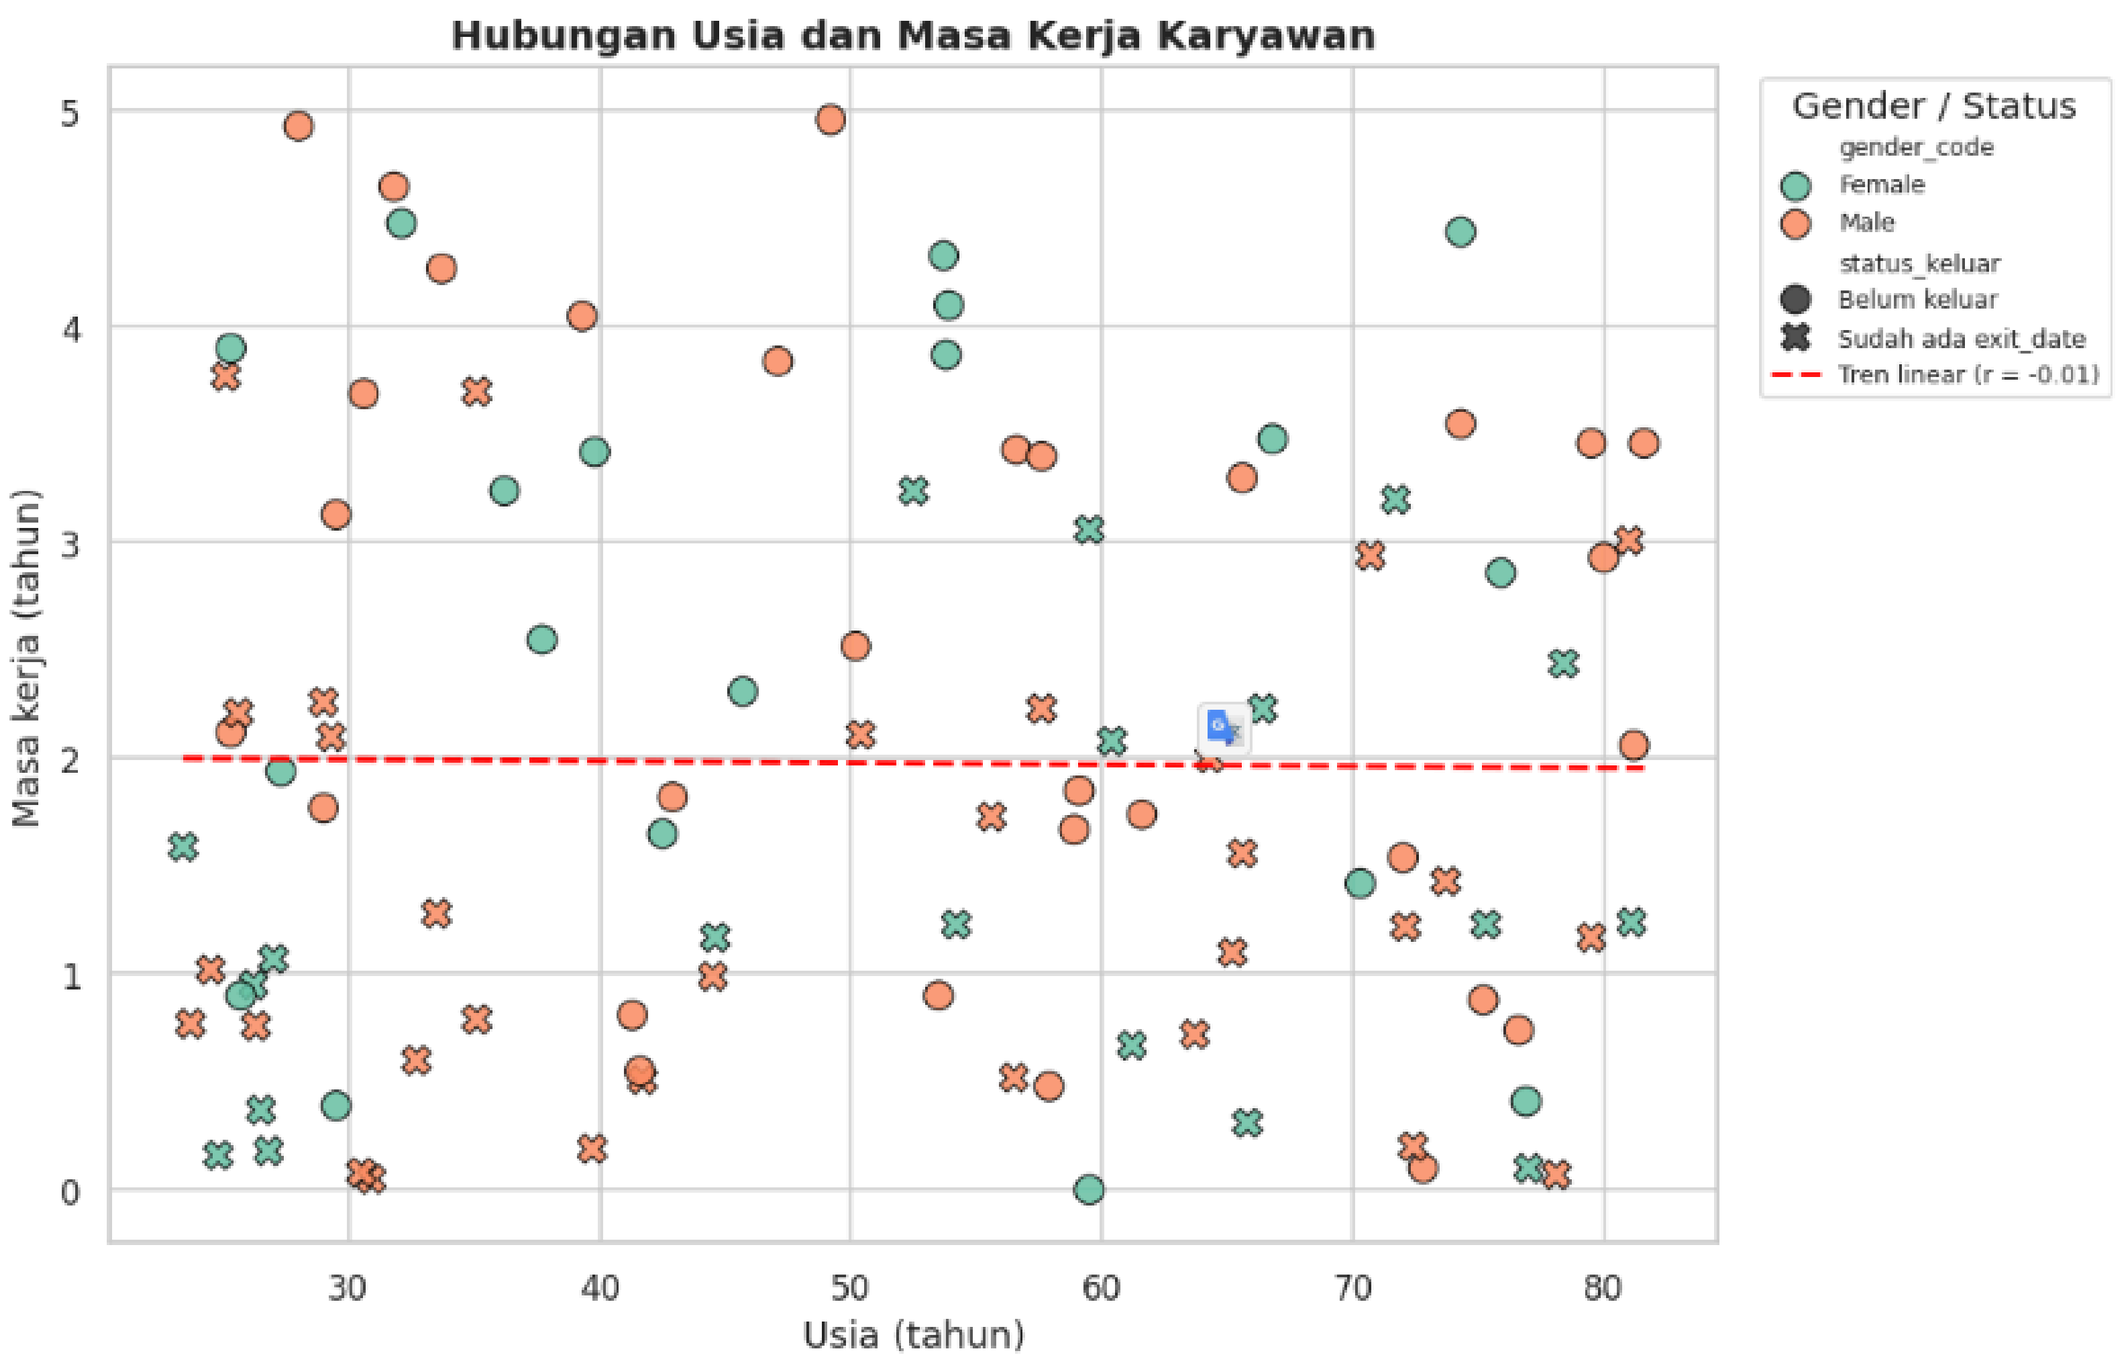
Insight: : karyawan yang keluar cenderung keluar pada tahun pertama sampai kedua, apa pun jenis terminasinya, sehingga risiko turnover terkonsentrasi di awal masa kerja. Ada juga kejanggalan data: karyawan berlabel Retirement memiliki rata-rata usia 55,3 tahun dan yang termuda 26,2 tahun, sehingga label ini perlu diverifikasi.

Scatter Plot

scatter plot memperlihatkan hubungan dua variabel numerik. Warna menunjukkan gender dan bentuk titik menunjukkan apakah karyawan sudah memiliki tanggal keluar. Garis putus-putus adalah tren linear.

```
d6 = dv.assign(status_keluar=np.where(dv['is_terminated'], 'Sudah ada exit_date', 'Belum keluar'))
fig, ax = plt.subplots(figsize=(10, 6.5))
sns.scatterplot(data=d6, x='age', y='tenure_years', hue='gender_code', style='status_keluar', s=90, alpha=.85,
                edgecolor='black', ax=ax)
r = d6['age'].corr(d6['tenure_years'])
m, b = np.polyfit(d6['age'], d6['tenure_years'], 1)
xs = np.linspace(d6['age'].min(), d6['age'].max(), 50)
ax.plot(xs, m * xs + b, 'r--', lw=1.8, label=f'Tren linear (r = {r:.2f})')
ax.set(title='Hubungan Usia dan Masa Kerja Karyawan', xlabel='Usia (tahun)', ylabel='Masa kerja (tahun)')
ax.legend(title='Gender / Status', loc='upper left', bbox_to_anchor=(1.02, 1), fontsize=8)
simpan('06_scatter_usia_masa_kerja')

print('Korelasi Pearson usia vs masa kerja:', round(r, 3), '| kemiringan:', round(m, 4), 'tahun masa kerja per tahun usia')
print(d6.groupby('gender_code')[['age', 'tenure_years']].mean().round(2))
```


Hubungan Usia dan Masa Kerja Karyawan
Masa kerja (tahun)
Usia (tahun)
0
1
2
3
4
5
30
40
50
60
70
80
Gender / Status
gender_code
Female
Male
status_keluar
Belum keluar
Sudah ada exit_date
Tren linear (r = -0.01)

Interpretasi

- Hubungan: korelasi usia dan masa kerja sangat lemah (r = -0,01) dan garis tren hampir datar di sekitar 2 tahun. Titik tersebar merata di seluruh bidang: karyawan muda maupun senior sama-sama ada yang masa kerjanya mendekati 0 dan ada yang mendekati 5 tahun.
- Gender: kedua gender menyebar di seluruh area plot tanpa kelompok yang terpisah. Rata-rata masa kerja hampir sama (perempuan 2,01 tahun, laki-laki 1,96 tahun) dan rata-rata usia juga mirip (50,8 dan 51,6 tahun).
- Status keluar: titik silang (sudah ada tanggal keluar) lebih banyak berada di bagian bawah plot, yaitu masa kerja di bawah sekitar 2 tahun, sejalan dengan temuan pada boxplot masa kerja.
- Insight: usia bukan penentu lamanya seseorang bertahan. Karena itu, usia tidak bisa dipakai sebagai dasar memprediksi retensi; faktor lain seperti unit kerja atau kondisi kerja perlu ditelaah.

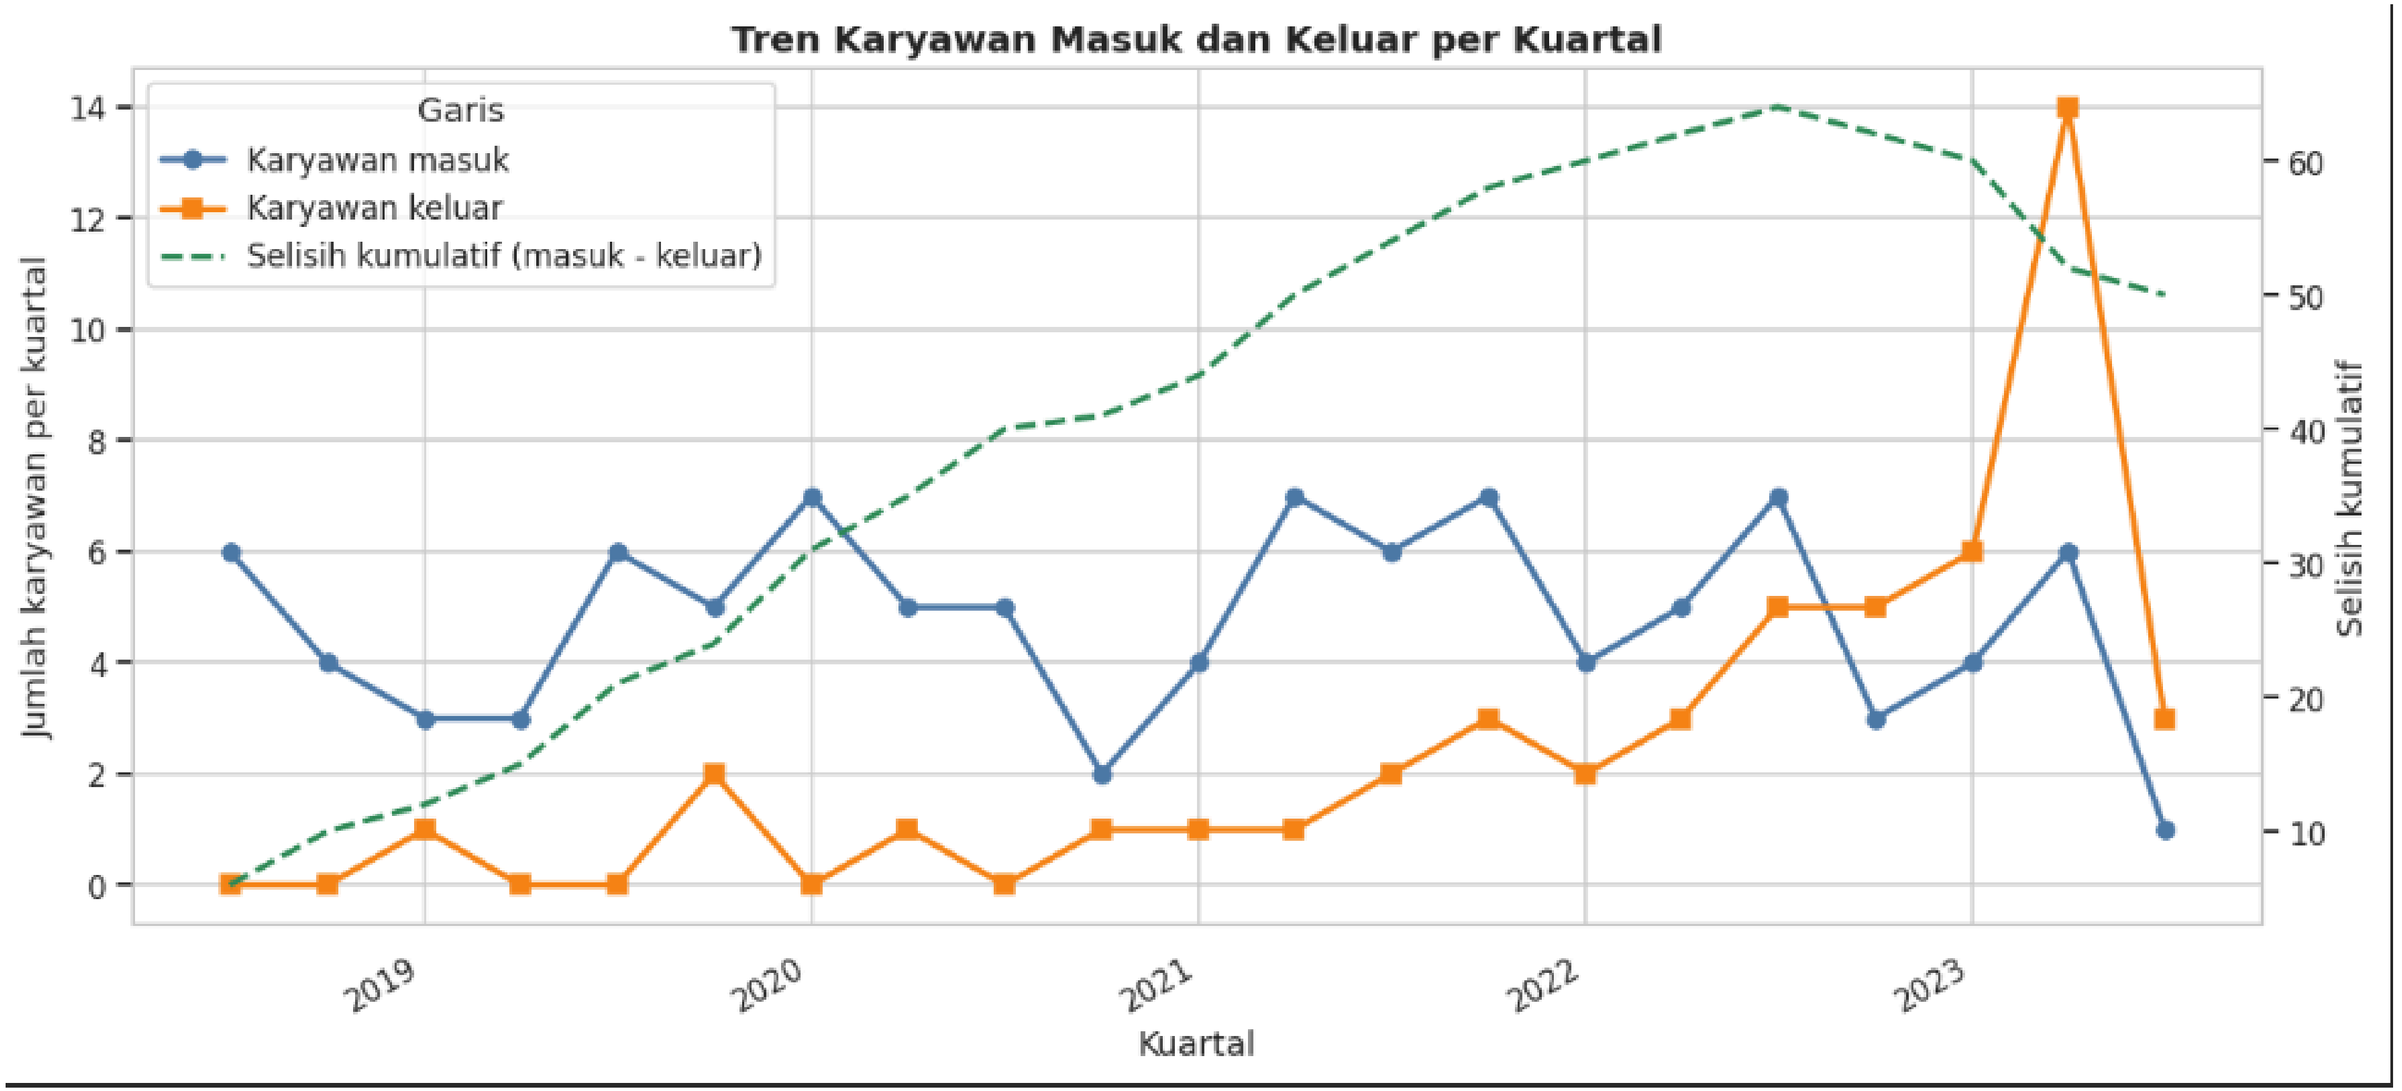
Line Chart

line chart menampilkan perubahan dari waktu ke waktu. Garis biru adalah jumlah karyawan masuk (start_date), garis oranye jumlah karyawan keluar (exit_date), dan garis hijau putus-putus (sumbu kanan) adalah selisih kumulatif masuk dikurangi keluar.

```
awal = min(dv['start_date'].min(), dv['exit_date'].min()).to_period('Q')
akhir = max(dv['start_date'].max(), dv['exit_date'].max()).to_period('Q')
idx = pd.period_range(awal, akhir, freq='Q')
masuk = dv['start_date'].dt.to_period('Q').value_counts().reindex(idx, fill_value=0).sort_index()
keluar = dv['exit_date'].dropna().dt.to_period('Q').value_counts().reindex(idx, fill_value=0).sort_index()
x = idx.to_timestamp()

fig, ax = plt.subplots(figsize=(12, 5.5))
ax.plot(x, masuk.values, marker='o', lw=2.2, color='#4C78A8', label='Karyawan masuk')
ax.plot(x, keluar.values, marker='s', lw=2.2, color='#F58518', label='Karyawan keluar')
ax.set(title='Tren Karyawan Masuk dan Keluar per Kuartal', xlabel='Kuartal', ylabel='Jumlah karyawan per kuartal')
ax2 = ax.twinx()
ax2.plot(x, (masuk - keluar).cumsum().values, ls='--', lw=2, color='#2E8B57', label='Selisih kumulatif (masuk - keluar)')
ax2.set_ylabel('Selisih kumulatif'); ax2.grid(False)
h1, l1 = ax.get_legend_handles_labels(); h2, l2 = ax2.get_legend_handles_labels()
ax.legend(h1 + h2, l1 + l2, title='Garis', loc='upper left')
fig.autofmt_xdate()
simpan('07_line_tren_masuk_keluar')

thn = pd.DataFrame({'masuk': masuk.groupby(masuk.index.year).sum(), 'keluar': keluar.groupby(keluar.index.year).sum()})
print(thn)
print('Kuartal masuk tertinggi:', str(masuk.idxmax()), masuk.max(), '| keluar tertinggi:', str(keluar.idxmax()), keluar.max())
print('Total masuk:', int(masuk.sum()), '| total keluar:', int(keluar.sum()), '| selisih akhir:', int((masuk - keluar).sum()))
print('Rentang start_date:', dv['start_date'].min().date(), 's.d.', dv['start_date'].max().date(),
      '| exit_date:', dv['exit_date'].min().date(), 's.d.', dv['exit_date'].max().date())
```



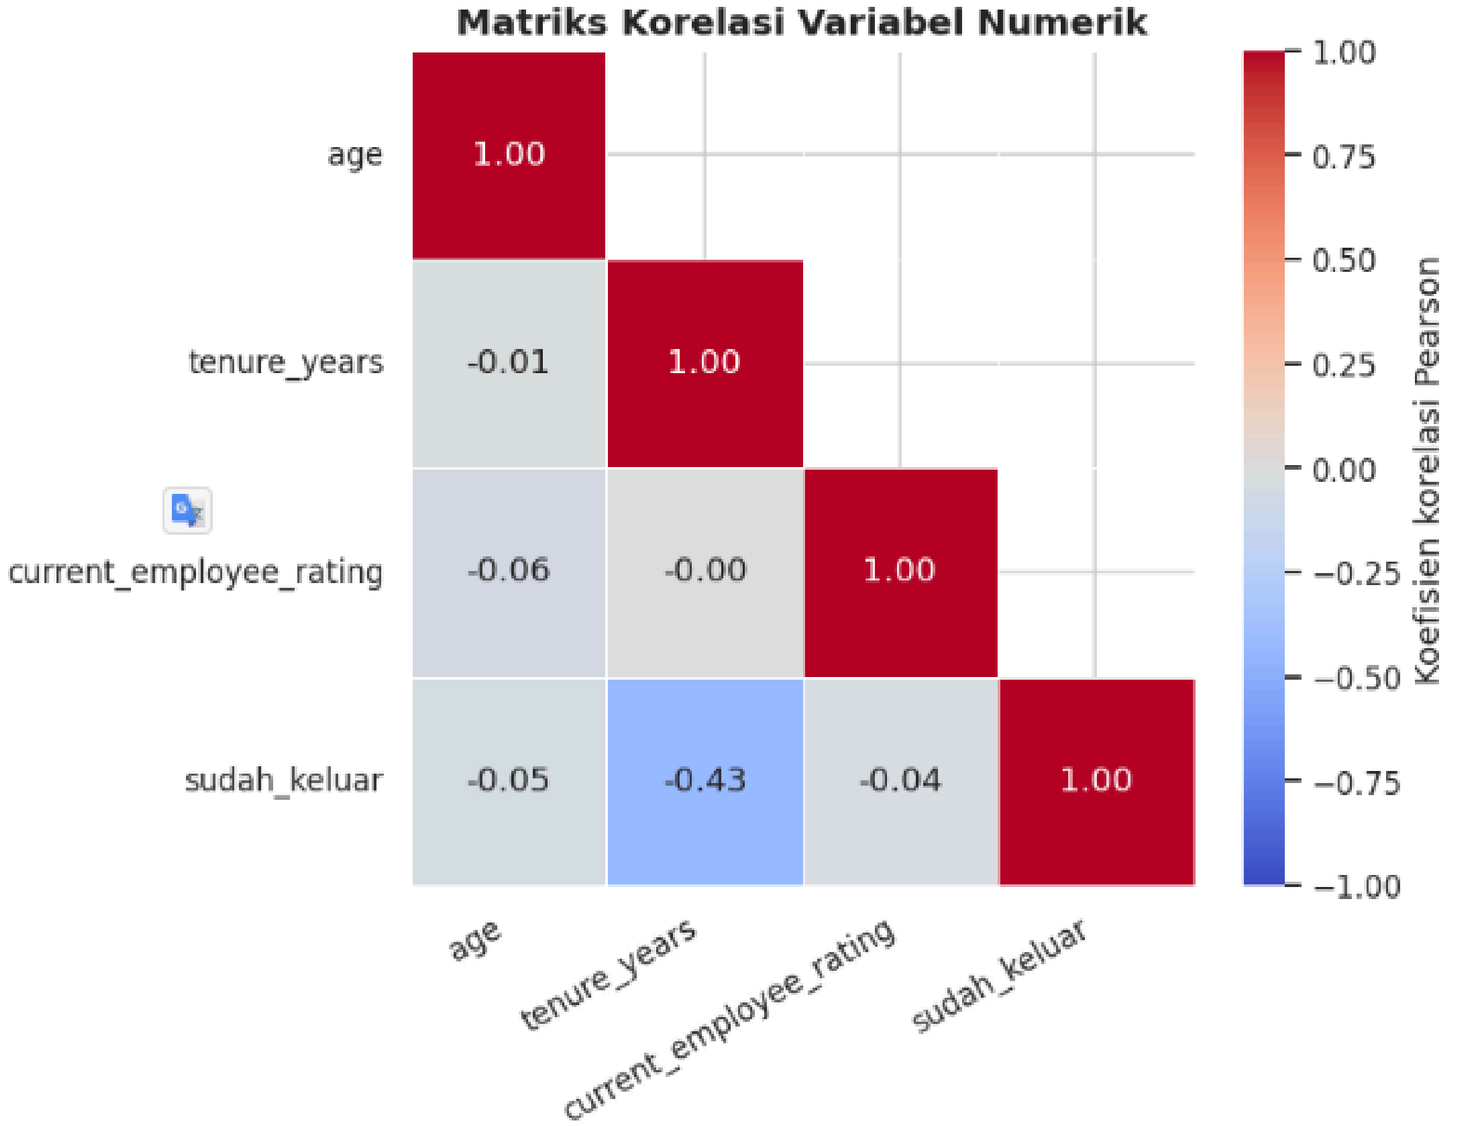
- Insight: perusahaan beralih dari fase ekspansi (2018–2021) ke fase penyusutan (sejak pertengahan 2022), dengan perekrutan melambat saat turnover meningkat. Catatan: kuartal ketiga 2023 belum lengkap karena data berhenti Agustus 2023, dan selisih kumulatif ini adalah indikator kasar karena 17 karyawan berstatus Future Start serta 33 berstatus Active pun tercatat memiliki tanggal keluar.

Heatmap

heatmap meringkas seluruh hubungan antarvariabel dalam satu matriks.
Merah = korelasi positif, biru = negatif, angka = koefisien Pearson.

```
num = dv[['age', 'tenure_years', 'current_employee_rating']].astype(float).assign(sudah_keluar=dv['is_terminated'].astype(int))
corr = num.corr()
mask = np.triu(np.ones_like(corr, dtype=bool), k=1)
fig, ax = plt.subplots(figsize=(7.5, 6))
sns.heatmap(corr, mask=mask, annot=True, fmt='.2f', cmap='coolwarm', vmin=-1, vmax=1, linewidths=.5,
            cbar_kws={'label': 'Koefisien korelasi Pearson'}, ax=ax)
ax.set_title('Matriks Korelasi Variabel Numerik')
plt.xticks(rotation=30, ha='right')
simpan('08_heatmap_korelasi')

pasang = corr.where(~mask & ~np.eye(len(corr), dtype=bool)).stack().dropna()
print(pasang.round(3).sort_values(key=abs, ascending=False).to_string())
```



- Insight: : pada data ini, usia, masa kerja, dan rating bergerak independen satu sama lain. Satu-satunya sinyal berarti adalah turnover terjadi pada karyawan dengan masa kerja pendek.

Kesimpulan

Tiga format tanggal masuk/keluar/lahir yang bercampur (20-Sep-19, 30-08-1965, 7/10/1969) disatukan menjadi satu format YYYY-MM-DD, spasi berlebih dirapikan (mis. Production), kategori dibakukan (Unk menjadi Unknown), dan nama kolom diseragamkan ke snake_case. Tidak ada duplikat maupun emp_id kembar, dan tidak ada tanggal yang gagal dibaca. exit_date sengaja dibiarkan kosong untuk 50 karyawan karena kosong berarti belum keluar. Empat kolom enrichment ditambahkan (age, age_group, tenure_years, is_terminated) dan dataset bersih disimpan ke Drive berdampingan dengan data mentah.

Tenaga kerja relatif baru (median masa kerja 1,76 tahun) dengan usia yang terbelah antara kelompok di bawah 30 tahun dan di atas 60 tahun. Business unit tersebar merata, tetapi division terpusat (tiga terbesar menampung 52%) dan 93% karyawan berada di department Sales. Kinerja seragam di semua tipe karyawan (74% Fully Meets). Usia tidak berhubungan dengan masa kerja, dan karyawan yang keluar umumnya pergi dalam 1–1,5 tahun pertama. Tren menunjukkan fase ekspansi sampai 2021 yang berbalik menjadi penyusutan sejak pertengahan 2022: pada 2023 yang keluar (23) dua kali lipat yang masuk (11).

THANK YOU